



HR ANALYTICS

DADOS NA CIÊNCIA GESTÃO E SOCIEDADE

Recursos Humanos

GRUPO 21

Ana Rita Rodrigues Nº 110823

Camila Sousa Nº 111017

Constança Brás Nº 110682

Mafalda Simões Nº 110607

Duarte Alcobia Nº 111309

Docentes:

Ana Maria Almeida

Miguel Salas Dias

outubro de 2022



Índice

1. Introdução.....	2
2. Metodologia Crisp-Dm	3
2.1. Business Understanding:	3
2.2. Data Understanding:	3
2.3. Data Preparation:	3
2.4. Modeling:.....	3
2.5. Evaluation:.....	3
2.6. Deployment:	3
3. Business Understanding	4
4. Data Understanding	5
4.1. Especificação das variáveis:	5
5. Data Preparation	7
5.1.1. 'Overtime'	9
5.1.2. 'Job Involvement'	9
5.1.3. 'Business Travel'	10
5.1.4. 'Monthly Income'	10
5.1.5. 'Marital Status'	11
5.1.6. 'Age' <> 'Years In Current Role'	11
6. Modeling.....	12
7. Conclusão.....	14
8. Referências.....	15

1. Introdução

Neste projeto, no âmbito da disciplina de Dados na Ciência, Gestão e Sociedade, pretendemos analisar, estruturar, entender e tirar conclusões acerca do *dataset* que nos foi disponibilizado.

Foram-nos apresentados vários temas e, entre todos, o que nos foi concedido foi o B (*Human Research*), onde o objetivo deste departamento é administrar os funcionários e alinhar os objetivos da empresa com os colaboradores, promovendo assim a satisfação profissional. Este estudo teve como ponto de partida a observação do Excel que nos foi disponibilizado, com dados adquiridos num questionário que nos permitiu obter algumas informações sobre os funcionários e ex-funcionários de uma empresa, pelo que se enquadraria no que é comumente conhecido como *HR Analytics* ou *People Analytics*.

Existem 35 variáveis dentro do tema, das quais tentámos relacionar para poder de uma melhor forma tratá-las, limpá-las e estruturá-las, conseguindo assim formular questões a partir das quais teríamos de responder e chegar à nossa conclusão final do relatório. Desta forma, utilizámos a metodologia CRISP-DM. Primeiramente entendemos o objetivo do nosso projeto e depois passámos à etapa *Data Preparation* onde transformamos o nosso *dataset* original no nosso *dataset* de modelagem para posteriormente construirmos o modelo. Para tal, utilizámos o programa *Orange* que nos ajuda a aplicar esta metodologia.

Ao explorarmos os dados, percebemos quais as variáveis que nos pareciam mais relevantes e interessantes para formular novos conhecimentos e previsões do tema. Acabámos assim por definir que o nosso target seria a variável “Attrition”, focando-nos no seguinte problema: “O que é que os Recursos Humanos (RH) podem fazer para evitar a saída dos trabalhadores na empresa? E como é que podem evitar o desgaste na mesma?”.

2. Metodologia Crisp-Dm

A realização deste trabalho seguiu a metodologia Crisp-Dm. O modelo Crisp-Dm (*Cross Industry Standard Process for Data Mining*) tem como finalidade o processamento de dados. Consiste num modelo que se divide em seis fases sequenciais.

2.1. Business Understanding: 'What does the business need?'. Esta etapa foca-se na compreensão dos objetivos e requisitos do projeto.

2.2. Data Understanding: 'What data do we have/need? Is it clean?'. Esta segunda etapa está direcionada para a identificação, reunião e análise dos conjuntos de dados.

2.3. Data Preparation: 'How do we organize the data for modeling?'. Esta terceira etapa corresponde a 80% do projeto, uma vez que prepara o(s) conjunto(s) de dados finais para modelação.

2.4. Modeling: 'What modeling techniques should we apply?'. Nesta quarta etapa o foco é na construção e avaliação dos dados com base em várias técnicas de modelação diferentes.

2.5. Evaluation: 'Which model best meets the business objectives?'. Na fase de avaliação, em comparação com a fase anterior, analisa mais amplamente qual o modelo que é mais relevante para o projeto e o que fazer em seguida.

2.6. Deployment: 'How do stakeholders access the results?'. Esta última etapa permite que o modelo se torne útil para que se possa aceder aos seus resultados.

3. Business Understanding

O departamento de Recursos Humanos (RH) numa empresa é fundamental. Os RH definem-se como a área que administra as pessoas a partir da aplicação de conhecimentos, e também de técnicas dirigidas à gestão das relações dentro de uma empresa. Este departamento tem ganho destaque ao longo dos tempos por ser tão essencial no ambiente de trabalho uma vez que permite um funcionamento adequado das empresas, assegurando uma maior produtividade e bem-estar dos seus trabalhadores. Assim, percebemos que uma empresa bem-sucedida é aquela que apresenta uma equipa de RH bem organizada e incisiva.

Esta é uma área que contém diversos propósitos, tais como: ajudar a empresa de modo a alcançar os seus objetivos; evitar conflitos de interesses, ao agir de modo a que seja possível existir um equilíbrio entre os objetivos trabalhadores e da empresa; contribuir para um melhor desempenho individual e organizacional; garantir que os profissionais se mantêm qualificados e motivados; assegurar a qualidade de vida no trabalho; gerir as mudanças ocorridas no meio de trabalho; contribuir de forma contínua com os esforços organizacionais de modo a que seja possível obter melhores níveis de qualidade, produtividade e de resultados.

Os RH integram-se e são responsáveis por diversos processos que se relacionam entre si. São exemplos o processo de aplicação, o de desenvolvimento de RH e o de monitorização de RH, que têm como objetivo decidir e selecionar quem irá trabalhar na empresa, o que passa pelo recrutamento e seleção de funcionários, mas também pela pesquisa de mercado. Através destes processos a manutenção dos trabalhadores passa por, por exemplo, remuneração dos salários, oferta de planos e benefícios sociais, controle e formação para o desenvolvimento do pessoal, melhoria as relações de trabalho, questões de higiene e segurança, o desenvolvimento de programas em função da melhoria do conhecimento do pessoal. Estas medidas garantem assim a produtividade e agilidade necessárias para manter a competitividade a nível económico.

4. Data Understanding

Este estudo tem como base os dados de funcionários e ex-funcionários.

Numa empresa, a substituição de funcionários, também conhecida como "employee churn", é um problema caro para as empresas, por vários fatores como por exemplo, a quantidade de tempo gasto para entrevistar e encontrar um substituto, à perda de produtividade por vários meses enquanto o novo funcionário se acostuma com a nova função, entre outros. A *HR Analytics* ajuda a prever o desgaste na empresa ("Attrition"), isto é, se os funcionários abandonam o emprego ou não, tornando possível reter os funcionários, prevenindo o prejuízo.

4.1. Especificação das variáveis:



- Age - Idade dos trabalhadores da empresa;
- Attrition - Se os trabalhadores saem da empresa ('yes'/'no');
- Business Travel - Frequência com que os trabalhadores viajam em trabalho. Esta variável pode ser analisada através de três opções: 'Travel Frequently', 'Travel Rarely', 'Non Travel';
- Daily Rate - Valor estimado que cada trabalhador ganha por dia por contrato;
- Department - Departamento em que a pessoa trabalha;
- Distance From Home - Distância de casa ao local de trabalho (km);
- Education - Nível de escolaridade;
- Education Field - Campo de Educação. Esta variável pode ser analisada através: 1 - 'Below College'; 2 - 'College'; 3 - 'Bachelor'; 4 - 'Master'; 5 - 'Doctor';
- Employee Count - Nº de empregado que a pessoa ocupa;
- Employee Number - Número de empregados;
- Environment Satisfaction - Nível de satisfação do trabalhador relativamente ao ambiente. Esta variável pode ser analisada através: 1 - 'Low'; 2 - 'Medium'; 3 - 'High'; 4 - 'Very High';
- Gender - Género do trabalhador;
- Hourly Rate - remuneração por hora por contrato;

- Job Involvement - Se o trabalhador se identifica com o emprego. Esta variável pode ser analisada através: 1 - 'Low'; 2 - 'Medium'; 3 - 'High'; 4 - 'Very High';
- Job Level - Nível de trabalho;
- Job Role - Papel que o trabalhador tem no trabalho;
- Job Satisfaction - Nível de satisfação do trabalhador relativamente ao emprego/trabalho. Esta variável pode ser analisada através: 1 - 'Low'; 2 - 'Medium'; 3 - 'High'; 4 - 'Very High'
- Marital Status - Estado civil. Esta variável pode ser analisada através: casado, solteiro, divorciado;
- Monthly Income - Salário mensal;
- Monthly Rate – Remuneração por mês/por contrato;
- Number Companies Worked -Número de empresas que trabalhou;
- Over 18 - Maior de 18;
- Percent Salary Hike - Percentagem de aumento salarial;
- Performance Rating - Nível de desempenho do trabalhador. Esta variável pode ser analisada através: 1 - 'Low'; 2 - 'Good'; 3 - 'Excellent'; 4- 'Outstanding'
- Relationship Satisfaction - Nível de satisfação do trabalhador relativamente às relações. Esta variável pode ser analisada através: 1 - 'Low'; 2 - 'Medium'; 3 - 'High'; 4 - 'Very High'
- Standard Hours - Horas base de cada trabalhador;
- Stock Option Level - Nível de ações que cada trabalhador possui dentro da empresa. Esta variável pode ser analisada através dos valores: 0, 1, 2 e 3;
- Total Working Years - Total de anos que trabalhou;
- Training Times Last Year - Número de formações que participou no último ano;
- Work Life Balance - Nível de equilíbrio na vida. Esta variável pode ser analisada através: 1 - 'Bad'; 2 - 'Good'; 3 - 'Better'; 4 - 'Best';
- Years At Company – Nº anos na empresa;
- Years In Current Role – Nº anos passados no atual papel de trabalho;
- Years Since Last Promotion – Nº anos desde a última promoção;
- Years With Current Manager – Nº anos passados com o atual gerente;


Após a análise das nossas variáveis e do nosso objetivo, por intuição, relacionámos o desgaste na empresa com a satisfação no emprego, passando agora para a fase de *Data Preparation* para verificar esta hipótese.

5. Data Preparation

Antes de passar os dados para o programa, fizemos um trabalho prévio de limpeza e organização de dados no Excel. Para isso, organizámos o texto em linhas para colunas. De seguida, filtrámos também os dados por variável para verificar que os dados estavam corretos e não havia dados em falta, ou errados (Figuras 1 e 2).



Posteriormente carregamos o documento em Excel com os dados para o file:



A partir daí começámos a transformar o nosso *data set* original num *data set* de modelagem. Este *dataset* contém 1470 instâncias e 35 variáveis das quais

tentámos relacionar para poder de uma melhor forma, tratá-los, limpá-los e estruturá-los.

Em primeiro lugar, corrigimos as variáveis 'Education', 'Environment satisfaction', 'Job involvement', 'Job level', 'Job Satisfaction', 'Performance rating', 'Relationship Satisfaction', 'Stock Option Level', 'Worklife Balance', no *widget* file (onde importámos o nosso *dataset*) que deveriam ser do tipo categórica, mas estavam definidas como numéricas. Esta mudança foi necessária visto que influencia a análise e a relação das mesmas.

Alterámos também a função "feature" para "skip" das variáveis 'Employee Count', 'Employee Number', 'Over 18', 'Standard Hours', uma vez que estas são obsoletas para o nosso *dataset* de modelagem, não influenciando nos restantes passos do projeto.

Atribuímos "skip" às variáveis "Hourly Rate", "Daily Rate", "Monthly Rate" por se tratar de variáveis de remuneração sem termos conhecimento do tipo de contrato das pessoas, isto é se recebem à hora, ao dia ou ao mês. Retiramos os departamentos uma vez que os 'Job Roles', os sub conjuntos dos departamentos, dão nos mais correlações com as restantes variáveis. Retiramos o gender após analisarmos que era irrelevante. Descartámos 'Percent Salary Hike', uma vez, sendo percentagens, não são valores fixos e variam com o salário de cada trabalhador.


Depois destes paços, obtemos o nosso *dataset* de modelagem. Tendo em conta o nosso objetivo referido na etapa anterior, seguimos para a fase de análise, e escolha das variáveis finais.

Passámos a estudar as variáveis que influenciam diretamente "Attrition", isto é, para a análise direta do que se relaciona com a saída dos trabalhadores.


Começamos a construir o nosso algoritmo, a partir do file adicionando os seguintes widgets:

- 'Select Columns' para definir o *target* como 'Attrition', onde vamos considerar e descartar as variáveis.
- 'Distribution', 'Scatter Plot', 'Rank' para que se pudessem analisar os dados e gráficos para o estudo do problema.

Depois desta construção, passamos à análise das variáveis para a seleção delas.




5.1.1. 'Overtime'




Neste gráfico foi escolhida a variável 'Overtime' associada à variável 'Attrition'. Verificamos que esta é uma das variáveis que mais afeta a 'Attrition'. Cerca de 30,33% das pessoas que realizam horas extra na empresa, tem mais tendência a sair. Por outro lado, notamos que aqueles que não exercem tempo extra na empresa não são propensos a abandonarem o trabalho, visto que apenas 10,44% é que realmente chegou a sair.

5.1.2. 'Job Involvement'




Para analisarmos este gráfico, mudámos a variável 'Job Involvement' de categórica para numérica de modo a conseguirmos utilizar uma das funcionalidades do ícone das 'Distributions' denominado de 'fitted probability'. Esta opção permitiu-nos criar as parábolas no gráfico acima, que nos ajudam a compreender que da mesma maneira que o 'job involvement aumenta menor é o número das pessoas que saem da empresa. Assim conseguimos observar que o 'Job Involvement' e a 'Attrition' se relacionam diretamente, uma vez que no caso de 'yes', ou seja, quando as pessoas realmente saem da empresa o 'Job Involvement' é menor. Já na hipótese 'no', onde as pessoas permanecem na empresa apresentam um envolvimento maior.

5.1.3. 'Business Travel'




Neste esquema analisámos o nosso *target* com a variável 'Business Travel' de modo a perceber como é que esta influência a 'Attrition'. Na categoria 'Travel Frequently' verificamos que 24,91% (cerca de um quarto do total das pessoas nesta categoria), que viajam regularmente no trabalho acabam por deixar na empresa. Da mesma maneira, as pessoas que viajam raramente ou até mesmo nada, têm muito menos tendência a sair da empresa. Este é um dado preocupante no ponto de vista empresarial, dado que a empresa perde trabalhadores quando estes realizam mais viagens.

5.1.4. 'Monthly Income'




Ao visualizarmos este gráfico inferimos que a existência de uma correlação entre o 'MonthlyIncome' e a 'Attrition' é bastante evidente. Os trabalhadores que recebem um salário mais baixo (entre 2000 e 7000) têm tendência a deixar a empresa com bastante facilidade comparativamente aos trabalhadores que têm salários mais elevados. Neste caso a 'Attrition' é bastante forte, demonstrando então a importância que o salário tem relativamente ao desejo de continuar na empresa. Nesta imagem observamos ainda que as linhas que acompanham os valores da "Attrition" seguem caminhos opostos uma vez que enquanto uma aumenta a outra diminui.

5.1.5. 'Marital Status'



Segundo este gráfico de barras, entendemos que o nosso *target* e a variável 'Marital Status' estão associados, o que não seria de esperar. Vemos que 25,53% dos solteiros saem da empresa, o que corresponde a uma percentagem significativa. Verifica-se ainda que os casados e divorciados saem muito menos (cerca de 12,5% e 10%, respetivamente).

5.1.6. 'Age' <> 'Years In Current Role'




Utilizamos a funcionalidade 'Scatter Plot' do Orange de modo a conseguirmos analisar três variáveis ao mesmo tempo, sendo elas 'Attrition', 'Age' e 'Years At Company'. Através da análise, observamos que os trabalhadores mais jovens (entre os 18 e os 36, considerados *Millennials*) que têm menos anos de trabalho na companhia têm mais tendência a deixar a empresa, contrariamente ao que acabámos de verificar, os trabalhadores com uma idade mais avançada (a partir dos 37), apresentam um tempo de trabalho na empresa já mais elevado, verificando que têm mais tendência a ficar na empresa.

6. Modeling/Evaluation/Deployment

Nesta parte, verificar e prever de resultados através do *machine learning*. Para isto, foram usados 3 modelos a fim de gerar uma ideia do que tinha uma maior *accuracy* na previsão. Entre os classificadores estão: o SVM (o modelo mais conhecido), a 'Logistic Regression', e 'Neural Network'. Fomos testar qual deles é que seria o mais acertado para que houvesse uma previsão mais fiel possível. Para isto fizemos a seguinte construção:

- 1º Ligar ao *widget* 'Select Columns' a um *widget* 'Select Rows', para selecionar apenas os trabalhadores que não saem;
- 2º Com o *widget* 'Data Sample', reduzimos os dados para um terço uma vez que são muitos mais do que a quantidade de pessoas que saem de modo a equilibrar e para o modelo conseguir criar padrões de maneira mais eficiente;
- 3º Após a análise das cinco diferentes 'Confusion Matrix' concluiu-se que o modelo que nos dava uma previsão mais real era o modelo SVM, ficando assim com a matriz:



Depois de seleccionar os dados das pessoas que saíram, ligámos ao *widget* 'Data Sample'. Nesta ligação configurámos o ponto de partida ao ponto de chegada, ligando 'Matching Date' a 'Date', para apenas os dados escolhidos no 'Select Rows' serem simplificados. Neste caso, reduzimos para menos de metade do número de dados de trabalhadores que não saíram da empresa. De seguida ligámos ao *widget* 'Concatenate' em *primary date*, de modo a juntar os dados das pessoas que não saíram (reduzidos/em menor quantidade) com os dados das pessoas que saíram da empresa. Para concatenar estes últimos fomos buscá-los ao 'Select Rows', mas na ligação 'Un-matching Data' – 'Adicional Data' para ir buscar os dados excluídos à seleção feita no 'Select Rows'.

Após a análise dos diferentes modelos em 'Confusion Matrix' e 'Test and Score' concluiu-se que o modelo que nos dava uma previsão mais real (com uma melhor *precision*), uma vez que é importante ter em conta o número de falsos positivos e falsos negativos. Neste caso seria menos prejudicial ter falsos negativos, e por isso o modelo mais indicado é o modelo SVM, apesar de ter menor precisão que 'Linear Regression'. No 'Test and Score' seleccionámos *training set size* a 90%, para estes dados serem de treino e os restantes de teste.

Test and Score - Orange

☐ Cross validation
Number of folds: 5
☒ Stratified

☐ Cross validation by feature

☒ Random sampling
Repeat train/test: 10
Training set size: 90 %
☒ Stratified

☐ Leave one out
☐ Test on train data
☐ Test on test data

Evaluation results for target (None, show average over classes)


Model	AUC	CA	F1	Precision	Recall
Logistic Regression	0.857	0.822	0.819	0.819	0.822
SVM	0.788	0.755	0.757	0.758	0.755
Neural Network	0.818	0.766	0.764	0.763	0.766

Compare models by: Area u. ☐ Negligible diff.: 0.1

	Logistic ...	SVM	Neural N...
Logistic Regression			
SVM			
Neural Network			

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

		Predicted		
		No	Yes	Σ
Actual	No	405	95	500
	Yes	86	154	240
	Σ	491	249	740



7. Conclusão

Após sintetizarmos e explorarmos os dados a partir do Orange, conseguimos determinar que as causas que faziam com que as pessoas saíssem mais das empresas, ou seja, que houvesse mais 'Attrition', eram o 'Over time', 'Job Involvement', 'Travel Frequently', 'Monthly Income', 'Job Satisfaction', 'Marital Status', "Age" e "Years At Company". Juntamente com estes dados e com a informação investigada no *Business Understanding*, conseguimos formular conhecimento e perceber que os Recursos Humanos podem passar a remunerar melhor o tempo extra, focando-se mais nos benefícios do funcionário havendo assim menos pessoas a sair. Observámos ainda que existem muitas saídas relacionadas com a falta de envolvimento dos funcionários, logo os recursos humanos poderiam desenvolver projetos de treino, de conhecimento pessoal cativando assim os operários. Dada a quantidade de trabalhadores que viajam muito frequentemente, e consequentemente deixam a empresa, os RH deveriam tentar evitar a admissão de quem viaja várias vezes. Por outro lado, o estado matrimonial dos operários é influente, mas neste caso os RH são impossibilitados de intervir pois não se podem basear se um trabalhador é casado, solteiro ou divorciado para o contratarem uma vez que não é ético.

Em resposta à segunda questão, para evitar o desgaste da empresa era mais vantajoso, se os RH contratassem trabalhadores de uma idade mais avançada, e que procurassem alguma estabilidade, pois verificámos que os funcionários jovens são mais prejudiciais para empresa pois saem mais. Assim, cada vez que um trabalhador sai é necessário contratar outro, havendo um maior gasto dos recursos da empresa que poderiam ser utilizados nos operários fiéis ao aumentar salários.

Concluimos assim com este projeto, que para que a empresa não fique prejudicada os RH devem agir de forma eficaz no recrutamento de novos trabalhadores, mais precisamente nas entrevistas de trabalho, tentando desde início perceber os objetivos a longo prazo dos trabalhadores de modo a tentar minimizar o desgaste empresarial.

8. Referências

<https://www.datascience-pm.com/crisp-dm-2/>

Recursos humanos: objetivos, funções e importância (trabalhador.pt)