

**Deteção de comunidades numa Rede Ego
Não Orientada de Contactos Presenciais
Entre Humanos**

Trabalho realizado no âmbito da Unidade
Curricular “Análise de Redes” do 3º ano da
Licenciatura em Ciência de Dados.

Docentes: Maria João Frazão Lopes

Carolina Brunheta 110888, CDC1

Camila Sousa 111017, CDC1

Grupo 4

Janeiro, 2025

Índice

Introdução	3
Q1. Detecção de comunidades	3
Aplicação dos Quatro Métodos de Detecção de Comunidades	8
1. Remoção de pontes.....	8
2. <i>Fast Greedy</i>	12
3. Algoritmo de Louvain	14
4. Propagação de etiquetas	17
Q2. Análise dos resultados obtidos	18
Apêndice – código utilizado	22

Introdução

A análise de redes surgiu como uma ferramenta essencial para o estudo de sistemas complexos, especialmente aqueles compostos por múltiplas entidades que interagem de forma dinâmica. Tais sistemas podem ser encontrados em diversos contextos, como redes sociais, biológicas e de informação. Compreender a estrutura subjacente a essas redes e a dinâmica das interações entre os seus componentes é fundamental para desvendar padrões e comportamentos. Nesse contexto, a segmentação de redes, ou detecção de comunidades, destaca-se como uma técnica crucial para identificar subgrupos coesos dentro de uma rede, que podem apresentar características únicas ou desempenhar papéis específicos no sistema.

O presente relatório foca-se na análise de uma rede ego não orientada, que representa contactos presenciais entre pessoas, cujos dados estão contidos no ficheiro "Lista de Ligações T2.txt", fornecido pela docente da unidade curricular. A rede consiste em nodos que representam indivíduos e ligações que indicam a existência de contato presencial entre eles. O objetivo é aplicar e avaliar quatro métodos distintos de detecção de comunidades: Remoção de Pontes, *Fast Greedy*, Algoritmo de Louvain e Propagação de Etiquetas. Cada método oferece diferentes perspetivas sobre a estrutura da rede, permitindo uma análise abrangente dos subgrupos formados.

Para cada método, serão extraídas informações como o número de comunidades detetadas, a dimensão de cada comunidade, o número de ligações internas e a densidade interna de cada comunidade, o número de ligações externas, e uma análise da coesão e separação das comunidades. Além disso, será realizada uma avaliação das partições com base na métrica modularidade. Os resultados obtidos serão comparados para entender como cada método captura diferentes aspetos das comunidades na rede. A análise será contextualizada com base na natureza da rede estudada, e todas as interpretações serão devidamente justificadas para garantir uma compreensão aprofundada dos fenómenos observados.

Q1. Detecção de comunidades

Comunidades

Uma comunidade, também conhecida como *cluster* ou módulo, é um subconjunto conexo de uma rede, onde os elementos possuem mais conexões entre si do que com o restante da rede. Por outras palavras, as comunidades são grupos de nodos, idealmente, com elevada coesão interna e separação externa, ou seja, há muitas ligações internas e poucas ligações com outros grupos. A importância das comunidades reside na sua capacidade de revelar a estrutura subjacente das redes, o que pode ter implicações práticas em diversas áreas, como as sociais, biológicas e tecnológicas.

Comunidades em Redes Sociais

No contexto das redes sociais, comunidades são agrupamentos de indivíduos que interagem de forma mais intensa e frequente entre si do que com o restante da rede. Essas interações refletem laços sociais, interesses em comum ou objetivos partilhados dentro do grupo. A identificação de comunidades permite dividir a rede em segmentos mais pequenos e compreensíveis, o que facilita a análise das dinâmicas internas e das relações significativas que existem entre os membros.

Ao revelar a estrutura subjacente de uma rede, as comunidades ajudam a entender como os indivíduos se organizam em grupos coesos, o que pode fornecer informações valiosas sobre comportamentos coletivos, padrões de comunicação e dinâmicas sociais. Compreender essas organizações é fundamental para prever como as influências se espalham, como os grupos interagem entre si e até como as informações ou tendências se disseminam, contribuindo para a análise mais eficaz de sistemas sociais e das suas interações.

Dado o papel fundamental que as comunidades desempenham, a próxima etapa crucial é a deteção dessas comunidades. Para identificar com precisão esses grupos, diferentes métodos de deteção de comunidades têm sido desenvolvidos, cada um com uma abordagem única para segmentar a rede de maneira eficaz. No próximo tópico, exploraremos quatro desses métodos, analisando as suas particularidades.

Métodos de deteção de Comunidades

Os métodos de deteção de comunidades são fundamentais para uma análise eficiente de redes, pois possibilitam a identificação automática das estruturas internas que as compõem. A seguir, passamos a enquadrar e detalhar quatro métodos de deteção de comunidades: Remoção de Pontes, *Fast Greedy*, Algoritmo de Louvain e Propagação de Etiquetas.

1. Remoção de Pontes

O método de Remoção de Pontes é uma técnica utilizada para identificar comunidades numa rede, focando-se especificamente nas ligações que desempenham um papel crucial na conexão entre diferentes subgrupos. Estas ligações, chamadas de "pontes", são identificadas pela sua alta intermediação, o que significa que aparecem com frequência nos caminhos mais curtos entre pares de nodos que pertencem a diferentes comunidades. Ao remover essas pontes, espera-se que a rede se divida em subredes conexas, permitindo identificar as comunidades.

A fórmula que define a intermediação de uma ligação e é:
$$Edge\ Betweenness(e) = \sum_{i \neq j} \frac{\sigma_{ij}(e)}{\sigma_{ij}}$$
 onde σ_{ij} é o número total de caminhos mais curtos entre os nodos i e j , e $\sigma_{ij}(e)$ é o número de caminhos mais curtos entre i e j que passam pela aresta e .

O algoritmo de Girvan e Newman é um algoritmo que utiliza esta medida. Durante a sua execução, é removida, em cada iteração, a ligação com maior intermediação, e a intermediação das demais ligações é recalculada, com vista a escolher a próxima ligação a retirar. Isto repete-se até que todas as ligações sejam removidas. A partição inicial contém todos os elementos da rede e a cada iteração cada *cluster* é dividido em dois (método hierárquico de divisão).

Este método pode ser particularmente útil em redes em que as pontes desempenham um papel fundamental na comunicação ou fluxo de informações. Contudo, a remoção de pontes pode resultar numa segmentação lenta e excessivamente fragmentada em redes mais densas, onde as divisões nem sempre refletem de maneira precisa as comunidades naturais da rede. Além disso, o algoritmo gera N partições sem indicação da sua qualidade, por isso é necessário que haja uma medida que meça a qualidade das partições.

2. Fast Greedy

O método *Fast Greedy* é um algoritmo hierárquico utilizado para detetar comunidades em redes, baseado na maximização da modularidade. O algoritmo é particularmente eficiente para redes de tamanho moderado e visa agrupar nodos de forma a otimizar globalmente a estrutura das comunidades.

A **modularidade**, que é a métrica base deste método, é uma medida que quantifica a qualidade de uma divisão da rede, avaliando se os nodos dentro de uma comunidade estão mais fortemente conectados entre si do que seria esperado aleatoriamente. É calculada comparando a densidade de ligações internas das comunidades com a densidade esperada de ligações internas numa rede aleatória, ou seja, uma rede onde os nodos são conectados de forma aleatória. A modularidade, numa rede não orientada e sem pesos associados às suas ligações é expressa pela seguinte fórmula: $Q = \frac{1}{L} \sum_c (L_c - \frac{k_c^2}{4L})$, com $Q < 1$, onde L é o número total de arestas na rede; L_c é o número de ligações internas da comunidade C ; K_c é a soma dos graus dos nodos dentro da comunidade C ; e $\sum c$ é o somatório de todas as comunidades.

O algoritmo *Fast Greedy* começa com a suposição de que cada nodo é uma comunidade independente. Inicialmente a modularidade é negativa, pois existem N *clusters*. De seguida, o algoritmo agrupa, iterativamente, as comunidades vizinhas para maximizar a modularidade (método hierárquico aglomerativo). A cada passo, calcula o ganho de modularidade que resulta da fusão das comunidades e escolhe a fusão que proporciona o maior ganho imediato na modularidade. Este processo é repetido até que não seja possível melhorar mais a modularidade, ou seja, até que a rede atinja uma configuração em que a modularidade não possa ser aumentada pela fusão de comunidades. Depois a modularidade decresce até 0, que representa o momento em que se obtém um só grupo.

Este método é eficiente por selecionar rapidamente fusões que aumentam a modularidade, sendo adequado para redes de tamanho moderado. Porém, pode ser menos eficaz em redes grandes devido à complexidade computacional e sensível à estrutura inicial da rede. Além disso, por ser uma heurística *greedy*, tende a obter soluções que não atingem o valor máximo de modularidade, e há bastante variação das dimensões dos grupos.

3. Algoritmo de Louvain

Tal como o *Fast Greedy*, o Algoritmo de Louvain partilha o princípio de otimização da modularidade. Na primeira fase, cada nodo da rede é inicialmente atribuído a uma comunidade separada, e os nodos são movidos entre as comunidades adjacentes para maximizar o ganho local de modularidade (método hierárquico aglomerativo). Esse processo de realocação é repetido até que não seja possível melhorar a modularidade.

Na segunda fase, as comunidades formadas são agrupadas em supernodos, onde cada supernodo representa uma comunidade identificada na fase anterior. As conexões entre esses supernodos são representadas por pesos, correspondendo à soma das conexões entre os nodos originais dentro de cada comunidade. Criam-se lacetes com peso igual à soma dos graus internos. O processo é então repetido, agora com esses novos supernodos, visando novamente maximizar a modularidade.

Este algoritmo é eficiente, especialmente para redes de grande escala, e tende a identificar comunidades com alta modularidade. A sua principal vantagem é a capacidade de produzir soluções rápidas e com alta precisão, tornando-o uma escolha popular na análise de redes complexas, e para redução rápida da dimensão da rede. Contudo, tal como no algoritmo *Fast Greedy*, a solução ótima geralmente não é ótima e depende da ordem pela qual os nodos são visitados. Para assegurar a reprodutibilidade dos resultados, foi utilizada uma *seed* 111 para a aplicação deste método.

4. Propagação de Etiquetas

A Propagação de Etiquetas é um método eficiente e simples para a deteção de comunidades em redes complexas, adequado especialmente para redes de grande escala, baseado na ideia de que os nodos adjacentes pertencem todos à mesma comunidade.

O processo é iterativo e funciona através da propagação de etiquetas entre nodos. Inicialmente, cada nodo recebe uma etiqueta única, e, ao longo das iterações, cada nodo adota a etiqueta mais comum entre os seus vizinhos. O processo continua até que todos os nodos tenham a etiqueta da maioria dos seus adjacentes, ou seja, até que a rede atinja o estado estacionário, onde cada comunidade é representada por uma etiqueta única. O algoritmo converge após um nº pequeno de iterações, independentemente da dimensão da rede.

Na solução, cada nodo tem mais adjacentes na sua comunidade do que em qualquer uma das outras comunidades, e por isso, o algoritmo gera comunidades fortes no sentido de definição menos restritivo.

Este método pode gerar resultados que variam dependendo da ordem em que os nodos são processados, uma característica que introduz uma componente estocástica no algoritmo. Para garantir a consistência nos resultados, é possível utilizar uma *seed* específica durante a execução, assegurando que os resultados sejam reproduzíveis. Foi utilizada uma *seed* 111.

A escolha do método adequado depende das características da rede em questão, podendo influenciar significativamente a qualidade da segmentação e a interpretação dos resultados. No próximo tópico, exploraremos como estes métodos podem ser aplicados à rede ego não orientada em estudo.

Considerações Gerais para Redes Ego:

Numa rede ego, o nodo central (ego) tem muitas conexões diretas, o que pode influenciar a maneira como as comunidades são formadas ao seu redor. Métodos que maximizam a modularidade, como o *Fast Greedy* e o Louvain, podem centralizar a comunidade em torno do nodo ego, o que pode ser uma desvantagem ou vantagem, por exemplo se o objetivo for uma análise mais focada na posição estratégica do ego na rede.

Como as redes ego tendem a ter conexões densas próximas ao nodo central, métodos como a Propagação de Etiquetas podem ter dificuldade em identificar comunidades distintas.

Métodos como a Remoção de Pontes podem ser úteis para destacar ligações críticas que conectam o nodo ego a diferentes subgrupos, especialmente se o objetivo for entender as interdependências na rede.

Aplicação dos Quatro Métodos de Detecção de Comunidades

1. Remoção de pontes

Para este primeiro método, as representações visuais das comunidades obtidas apresentam-se na Figura 1 e a constituição das comunidades detetadas na Tabela 1.




Figura 1 - Visualização das comunidades detetadas pelo método Remoção de pontes

Tabela 1 – Constituição das comunidades detetadas pelo método Remoção de pontes

Comunidade	Número de nodos	Ligações Internas	Ligações externas	Densidade interna
1	17	47	50	0.35
2	13	32	24	0.41
3	7	14	13	0.67
4	3	2	7	0.67
5	1	0	1	NaN
6	1	0	2	NaN
7	2	1	2	1.00
8	2	1	3	1.00
9	1	0	1	NaN
10	2	1	4	1.00
11	2	1	5	1.00

Análise do método:

- Número de comunidades:** O método de Remoção de Pontes identificou 11 comunidades. Este número indica uma fragmentação significativa da rede, sendo que a maioria das comunidades é composta por um número reduzido de nós, exceto a Comunidade 1, que se destaca por ser a maior.
- Dimensão das comunidades:** A Comunidade 1 é a mais extensa, com 17 nodos, concentrando uma maior parte da rede. As comunidades 2 e 3 também apresentam tamanhos razoáveis, com 13 e 7 nodos, respetivamente. As restantes comunidades (4 a 11) são bastante pequenas,

com menos de 4 nodos cada, destacando-se várias comunidades de tamanho unitário. Essa fragmentação em comunidades pequenas pode indicar a presença de subestruturas periféricas ou áreas da rede menos conectadas.

3. Número de ligações internas de cada comunidade e respetiva densidade

interna: A densidade interna varia significativamente entre as comunidades. A Comunidade 3, por exemplo, apresenta uma densidade alta (0,67), tal como a Comunidade 4. Já a Comunidade 1, mesmo tendo o maior número de ligações internas (47), possui uma densidade mais baixa (0,35), refletindo a diluição das ligações em relação ao seu tamanho. As comunidades com 2 nodos (7, 8, 10, 11) têm densidade interna de 1. Isso é esperado, uma vez que basta que os nodos tenham ligação entre si para atingirem o máximo de ligações internas possível. Comunidades como 5, 6 e 9 (unitárias) não apresentam densidade interna calculada, pois há ausência de ligações internas.

4. Número de ligações externas de cada comunidade:

A Comunidade 1 possui o maior número de ligações externas (50), sugerindo que, apesar de ser a maior, não está bem separada do resto da rede. As comunidades periféricas (6, 7, 8, 10, 11) têm pouquíssimas ou nenhuma ligação externa, o que sugere uma melhor separação dessas comunidades. Algumas comunidades menores, como a 4 (7 ligações externas), possuem uma proporção elevada de ligações externas, o que pode indicar baixa separação.

5. Coesão e a separação da partição obtida:

Para avaliar a **coesão**, que indica o grau de conectividade interna, comparámos as ligações internas de cada comunidade com o número máximo de ligações possíveis $L_{max} = \frac{N(N-1)}{2}$ onde N é o número de nodos da comunidade. A densidade interna, apresentada na tabela 1, é o resultado desta comparação, onde valores próximos de 1 indicam alta coesão:

- Comunidade 1: A densidade interna é relativamente baixa, indicando que a conectividade entre os membros da comunidade é limitada em relação ao número máximo possível de ligações, o que mostra uma baixa coesão;
- Comunidade 2: A densidade interna é moderada, refletindo uma coesão superior à da Comunidade 1, mas ainda longe de ser alta;
- Comunidade 3: A densidade interna é consideravelmente maior, mostrando uma comunidade mais coesa, com uma alta proporção de ligações internas em relação ao número máximo possível;

- Comunidade 4: A densidade interna é alta, característica típica de comunidades pequenas, onde a coesão é maximizada devido ao número reduzido de nodos.
- Comunidades 5, 6 e 9: A densidade interna é máxima, pois só é possível uma ligação interna, logo a coesão é total;
- Comunidades 7, 8, 10 e 11: Como não existem ligações internas, não é possível avaliar a coesão.

De um modo geral, observa-se que comunidades menores tendem a ser mais coesas, o que é de esperar visto que o número possível de ligações internas é menor, enquanto comunidades maiores apresentam uma conectividade mais dispersa.

A **separação** foi avaliada pelo quociente $\frac{L_{ext}}{L_{total}}$, onde L_{ext} são as ligações externas e $L_{total} = L_c + L_{ext}$. Foi considerado que valores superiores a 0,25 indicam uma má separação:

- Comunidade 1: $L_{ext}= 50$ e $L_{total}= 97$. O quociente é $\frac{50}{97} \approx 0,51$, indicando uma separação fraca, com mais de metade das ligações conectadas a outras comunidades;
- Comunidade 2: $L_{ext}= 24$ e $L_{total}= 56$. O quociente é $\frac{24}{56} \approx 0,43$, também indicativo de má qualidade de separação;
- Comunidade 3: $L_{ext}= 13$ e $L_{total}= 27$. O quociente é $\frac{13}{27} \approx 0,48$, e por isso esta comunidade está também mal separada;
- Comunidade 4: $L_{ext}= 7$ e $L_{total}= 9$. O quociente é $\frac{7}{9} \approx 0,78$, evidenciando uma separação fraca, com quase todas as suas ligações sendo externas;
- Comunidade 5: $L_{ext}= 1$ e $L_{total}= 1$. O quociente é $\frac{1}{1} \approx 1$, logo a comunidade não está separada da rede;
- Comunidade 6 e 9: $L_{ext}= 2$ e $L_{total}= 2$. O quociente é $\frac{2}{2} \approx 1$, sugerindo, também, a inexistência da separação da comunidade da rede;
- Comunidade 7: $L_{ext}= 2$ e $L_{total}= 3$. O quociente é $\frac{2}{3} \approx 0,67$, apontando para uma separação muito fraca;
- Comunidade 8: $L_{ext}= 3$ e $L_{total}= 4$. O quociente é $\frac{3}{4} \approx 0,75$. Separação muito fraca;
- Comunidade 10: $L_{ext}= 4$ e $L_{total}= 5$. O quociente é $\frac{4}{5} \approx 0,8$, o que reforça uma separação muito fraca;
- Comunidade 11: $L_{ext}= 5$ e $L_{total}= 6$. O quociente é $\frac{5}{6} \approx 0,83$. A separação é muito limitada.

A baixa separação sugere que as comunidades estão altamente conectadas umas às outras. Em redes sociais, poderá significar que os

grupos (comunidades) interagem frequentemente entre si, sem formar subgrupos bem definidos. Na rede em estudo, uma observação da figura 1 demonstra que grande parte das ligações externas das comunidades estão conectadas à comunidade à qual pertence o nodo ego (nodo 26), o que é de esperar, visto que esta é uma rede ego (logo todos os nodos se ligam ao nodo ego).

A presença de muitas conexões externas enfraquece os limites entre as comunidades, dificultando a sua diferenciação. Isso pode ser uma limitação do método utilizado (remoção de pontes) ou, como as observações anteriores sugerem, uma característica intrínseca das redes ego.

- 6. Modularidade:** Com uma modularidade de 0,322, a qualidade da partição das comunidades não é particularmente elevada. Isso sugere que as comunidades identificadas não maximizam a separação das estruturas internas. Idealmente, uma modularidade acima de 0,4 é considerada boa.

2. *Fast Greedy*

Para este método, as representações visuais das comunidades obtidas apresentam-se na Figura 2 e a constituição das comunidades detetadas na Tabela 2.




Figura 2 - Visualização das comunidades detetadas pelo método *Fast Greedy*

Tabela 2 – Constituição das comunidades detetadas pelo método *Fast Greedy*

Comunidade	Número de nodos	Ligações Internas	Ligações externas	Densidade interna
1	17	38	25	0.28
2	12	20	25	0.30
3	11	23	27	0.42
4	11	13	45	0.24

Análise do método:

- 1. Número de comunidades:** O método *Fast Greedy* detetou 4 comunidades, um número menor comparado ao método de Remoção de Pontes, sugerindo que ao priorizar uma maior modularidade, o agrupamento foi feito em comunidades maiores.
- 2. Dimensão das comunidades:** A distribuição das dimensões das comunidades é relativamente homogénea, com todas as comunidades tendo dimensões médias ou grandes. Não há comunidades muito pequenas, o que indica uma tendência do algoritmo de evitar *clusters* pequenos.
- 3. Número de ligações internas de cada comunidade e respetiva densidade interna:** As comunidades apresentam, em geral, densidades internas baixas. A Comunidade 3 destaca-se pela maior densidade, enquanto a Comunidade 4, mesmo com menos nodos, tem a densidade interna mais baixa (0,24), sugerindo ligações internas limitadas.
- 4. Número de ligações externas de cada comunidade:** A Comunidade 4 tem o maior número de ligações externas, o que sugere que está fortemente conectada ao restante da rede, indicando baixa separação. As Comunidades 1, 2 e 3, com números similares de ligações externas entre si, indicam que, apesar de não estarem isoladas, possuem menor dependência externa em relação à Comunidade 4.
- 5. Coesão e a separação da partição obtida:** Sobre a **coesão** das comunidades pode-se concluir que:
 - Comunidade 1: Embora tenha um número significativo de ligações internas, a densidade interna é relativamente baixa. Isto ocorre porque a conectividade é diluída pelo maior número de membros da comunidade, o que resulta numa proporção mais baixa de ligações internas em relação ao número máximo possível de conexões, ou seja, numa menor coesão;
 - Comunidade 2: A densidade interna é ligeiramente maior do que na Comunidade 1, mas ainda assim permanece baixa. Apesar de ter um número considerável de ligações internas, o número de membros na comunidade ainda contribui para uma coesão não muito forte;
 - Comunidade 3: Aqui, a densidade interna é significativamente mais alta, indicando uma maior conectividade entre os membros. A comunidade apresenta uma proporção mais elevada de ligações internas em relação ao total possível, refletindo uma maior coesão;

- Comunidade 4: A densidade interna é a mais baixa entre as comunidades, sugerindo uma conectividade interna fraca. Embora haja ligações internas, são limitadas em relação ao número de membros da comunidade, resultando numa coesão mais baixa.

Após calcular o quociente $\frac{L_{ext}}{L_{total}}$ para as 4 comunidades, pode-se retirar conclusões sobre a **separação** das comunidades: a comunidade 1, com 40% das suas ligações fora da comunidade, mostra uma separação insatisfatória mas moderada; as comunidades 2 e 3, em que mais de metade das conexões são externas (56% e 54%, respetivamente), apresenta uma separação fraca; a comunidade 4, com quase 80% das ligações a conectarem-se externamente, revela ser uma comunidade mal isolada da rede com separação extremamente baixa.

6. **Modularidade:** O valor de modularidade obtido pelo método *Fast Greedy* é 0,3484, um aumento em relação à modularidade obtida pelo método de Remoção de Pontes (0,3222). Embora este valor indique uma melhoria em termos de agrupamento global, ainda é moderado, considerando que valores acima de 0.4 são, geralmente, associados a boas partições. Valores baixos de coesão e os altos índices de separação mostram que o aumento na modularidade pode ser superficial, refletindo comunidades que são mais artificiais do que naturais na rede. Isso implica que, embora as comunidades possam apresentar uma certa separação em termos de ligações internas e externas, essa separação não é acompanhada de uma forte coesão, o que limita a qualidade e a robustez das partições obtidas.

3. Algoritmo de Louvain

Para este método, as representações visuais das comunidades obtidas apresentam-se na Figura 3 e a constituição das comunidades detetadas na Tabela 3.




Figura 3 - Visualização das comunidades detetadas pelo Algoritmo de Louvain

Tabela 3 – Constituição das comunidades detetadas pelo Algoritmo de Louvain

Comunidade	Número de nodos	Ligações Internas	Ligações externas	Densidade interna
1	9	17	21	0.47
2	18	32	46	0.21
3	9	20	21	0.56
4	7	14	13	0.67
5	8	10	23	0.36

Análise do método:

- Número de comunidades:** O método Louvain identificou 5 comunidades, representando uma segmentação moderadamente detalhada da rede. Comparado aos outros métodos, oferece mais granularidade do que o *Fast Greedy* (4 comunidades), mas menos fragmentação do que o método de Remoção de Pontes (11 comunidades).
- Dimensão das comunidades:** A distribuição das dimensões das comunidades varia significativamente, existindo uma certa diversidade. A comunidade 2 destaca-se como a maior, reunindo uma parcela considerável da rede. No entanto, a presença de comunidades menores, como a comunidade 4 e 5, evidencia a habilidade deste método em identificar agrupamentos menores.
- Número de ligações internas de cada comunidade e respetiva densidade interna:** As comunidades apresentam variações nas suas ligações internas e densidade interna, refletindo diferentes estruturas de conectividade. A Comunidade 4, com a maior densidade interna (0,67), tem uma forte conexão interna, apesar de ser pequena. Já a Comunidade 3, com densidade de 0,56, mostra, também, uma conectividade razoável e mais ligações internas que a 4. A Comunidade 1 (densidade de 0,47) apresenta um número moderado de ligações, enquanto a Comunidade 5, com a menor densidade interna (0,36), indica uma conectividade mais fraca e dispersa (menos ligações internas). Por fim, a Comunidade 2, apesar de ter muitos nodos (18), tem a densidade interna mais baixa (0,21), sugerindo uma rede interna fraca, com ligações menos concentradas entre os seus membros.
- Número de ligações externas de cada comunidade:** A comunidade 2 é a mais conectada ao restante da rede, com 46 ligações externas, estando bastante integrada à rede global, o que pode indicar uma maior interação com outras partes do sistema e uma maior dependência externa. A comunidade 5, com 23 ligações externas, apresenta também uma alta conectividade externa, mas em menor escala, indicando que, embora conectada, tem uma interação um pouco mais limitada com o restante da

rede. As comunidades 1 e 3, com 21 ligações externas, têm um grau de dependência externo mais moderado. Já a comunidade 4, com 13 ligações externas, apresenta o menor número de ligações externas, o que sugere que está relativamente mais isolada em relação às outras comunidades da rede, mas isso pode dever-se ao facto desta comunidade ter menos nodos.

5. Coesão e a separação da partição obtida: A coesão e a separação para cada comunidade, com base nas suas densidades internas e no número de ligações externas são:

- Comunidade 1: Com 9 nodos e 17 ligações internas, a densidade interna é de 0,47, o que sugere uma conectividade moderada dentro da comunidade. Embora haja ligações significativas, a proporção de conexões internas não é muito alta, refletindo uma coesão razoável, mas não totalmente forte. Em termos de separação, a comunidade tem uma quantidade considerável de ligações externas, o que sugere que a sua separação é pouco pronunciada;
- Comunidade 2: Com 18 nodos e 32 ligações internas, a densidade interna de 0,21 é a mais baixa entre as comunidades, o que indica uma conectividade interna fraca. A grande quantidade de nodos contribui para a dispersão das ligações, diminuindo a coesão. Em termos de separação, a Comunidade 2 tem muitas ligações externas (46), o que a coloca numa posição de fraca separação, com muitas conexões com outras partes da rede;
- Comunidade 3: A Comunidade 3, com 9 nodos e 20 ligações internas, apresenta maior densidade interna (0,56), refletindo uma conectividade interna forte. A proporção de ligações internas em relação ao total possível é superior a metade, indicando uma coesão razoável. Quanto à separação, a comunidade mantém um número razoável de ligações externas, mas a conectividade interna mais forte sugere uma separação moderada;
- Comunidade 4: Com 7 nodos e 14 ligações internas, tem a maior densidade interna (0,67), o que reflete uma melhor coesão. As ligações internas representam uma parte significativa da conectividade, sugerindo uma estrutura mais fechada e coesa. A separação, no entanto, não é muito alta;
- Comunidade 5: Com 8 nodos e 10 ligações internas, a densidade interna (0,36) é baixa, indicando uma fraca coesão da comunidade. Embora não seja a mais separada, a sua estrutura sugere uma separação baixa, com ligações externas (23) mais expressivas, o que demonstra que a comunidade é mais permeável, com interações mais frequentes com o resto da rede.

6. Modularidade: O valor de modularidade obtido foi 0,3671, superior aos dois métodos anteriores, sugerindo uma partição de qualidade ligeiramente melhor. No entanto, essa modularidade ainda é moderada, o que indica que há uma interligação considerável entre as comunidades. Portanto, embora

o método Louvain tenha gerado uma partição razoável, ainda apresenta desafios no que diz respeito à definição de fronteiras mais nítidas e ao fortalecimento das conexões internas.

4. Propagação de etiquetas

Para este método, as representações visuais das comunidades obtidas apresentam-se na Figura 4 e a constituição das comunidades detetadas na Tabela 4.




Figura 4 - Visualização das comunidades detetadas pelo método Propagação de etiquetas

Tabela 4 – Constituição das comunidades detetadas pelo método Propagação de Etiquetas

Comunidade	Número de nodos	Ligações Internas	Ligações externas	Densidade interna
1	44	128	13	0.14
2	7	14	13	0.67

Análise do método:

- Número de comunidades:** O método de Propagação de Etiquetas identificou 2 comunidades, apresentando uma segmentação bastante simples e com pouca granularidade, quando comparado aos métodos anteriores. A simplicidade do modelo pode ser vantajosa em algumas situações, mas também pode indicar uma perda de detalhes relevantes na estrutura da rede.

- 2. Dimensão das comunidades:** A distribuição das dimensões das comunidades é muito desigual: a Comunidade 1 possui 44 nodos, enquanto a Comunidade 2 é bem menor, com apenas 7 nodos. A grande diferença no tamanho das comunidades sugere que o método de Propagação de Etiquetas pode não ter capturado nuances mais detalhadas da rede, resultando em comunidades de tamanhos extremamente discrepantes.
- 3. Número de ligações internas de cada comunidade e respetiva densidade interna:** A comunidade 1, com 44 nodos e 128 ligações internas, apresenta uma densidade interna muito baixa (0,14), o que sugere uma conectividade interna fraca e uma grande dispersão das ligações. Já a Comunidade 2, com 7 nodos e 14 ligações internas, tem uma densidade interna alta (0,67), com a maioria das conexões concentradas dentro da própria comunidade.
- 4. Número de ligações externas de cada comunidade:** Ambas as comunidades têm o mesmo número de ligações externas (13). No caso da Comunidade 1, isso significa uma boa separação do resto da rede, já que o número de ligações internas é muitíssimo superior (128). No caso da comunidade 2, que tem apenas 14 ligações internas, este número de ligações externas demonstra uma grande conectividade ao resto da rede.
- 5. Coesão e a separação da partição obtida:** A coesão e a separação são bastante contrastantes entre as duas comunidades:
- Comunidade 1: Com uma densidade interna baixa (0,14) e poucas ligações externas (13), a comunidade apresenta uma estrutura dispersa, sem uma coesão interna robusta, mas tem uma boa separação;
 - Comunidade 2: Apesar de ter uma densidade interna alta (0,67), a separação externa é baixa, com 13 ligações externas vs. 14 internas. Embora bem coesa internamente, a comunidade ainda mantém interação com o restante da rede, o que impede um isolamento completo.
- 6. Modularidade:** O valor de modularidade obtido foi 0,1457, significativamente mais baixo do que os valores obtidos com os métodos anteriores, o que indica uma partição de qualidade bastante inferior. A modularidade tão baixa sugere que, apesar da separação das comunidades, a estrutura da rede não é bem otimizada. A separação entre as comunidades não é suficientemente forte, e a rede apresenta uma interligação considerável entre as comunidades, evidenciando que o método de Propagação de Etiquetas não foi eficaz em criar divisões claras e robustas.

Q2. Análise dos resultados obtidos

A comparação dos resultados obtidos pelos quatro métodos de deteção de comunidades (Remoção de Pontes, *Fast Greedy*, Algoritmo de Louvain e Propagação de Etiquetas) revela diferentes abordagens na segmentação da rede, com implicações distintas sobre a coesão, a separação e a modularidade das comunidades identificadas. Esta secção é destinada à discussão dos principais aspetos de cada método e à comparação dos seus resultados.

Método de Remoção de Pontes

Este método identificou 11 comunidades, com grande fragmentação da rede, evidenciada por várias comunidades de pequena dimensão. A baixa modularidade (0,322) e a alta interconectividade entre as comunidades indicam que a separação entre as mesmas não foi eficaz, comprometendo a capacidade de gerar grupos distintos e coesos.

Método *Fast Greedy*

Identificou 4 comunidades, o que representa uma segmentação mais simplificada em comparação com o método anterior. A modularidade aumentou para 0,348, mas ainda é considerada baixa. A análise das ligações internas e externas revelou que as comunidades não estavam bem separadas, com altas proporções de conexões externas, especialmente a Comunidade 4, que estava muito interconectada ao restante da rede.

Algoritmo de Louvain

Este método foi o que apresentou a melhor modularidade, com um valor de 0,3671, superior aos outros métodos. Identificou 5 comunidades, equilibrando bem a segmentação e a separação entre as partes da rede. A análise da densidade interna das comunidades revelou uma conectividade razoável, com algumas comunidades (como a 4) apresentando uma boa coesão interna. Contudo, a separação entre algumas comunidades ainda foi moderada, especialmente para as maiores, como a Comunidade 2, que apresentou uma conectividade interna baixa e uma alta quantidade de ligações externas.

Método de Propagação de Etiquetas

Este foi o pior método. Identificou apenas 2 comunidades. A baixa modularidade e a fraca coesão interna nas comunidades indicam que este método não foi eficaz em criar divisões significativas ou representativas da estrutura da rede, resultando numa segmentação muito simples e insuficiente.

Melhor Método

Considerando os resultados obtidos, o **Algoritmo de Louvain** foi o melhor método de detecção de comunidades entre os avaliados, com base em vários critérios: modularidade, diversidade das comunidades, coesão e separação. Este destaca-se principalmente pela sua capacidade de oferecer uma segmentação equilibrada, que reflete melhor a estrutura da rede, com uma modularidade aceitável e boas características de separação e coesão interna. Embora existam limitações, como a necessidade de melhorar a separação em comunidades maiores, o Louvain demonstrou ser o mais eficaz para este caso específico.

Interpretação




Figura 5 - Visualização das comunidades detetadas pelo Algoritmo de Louvain

Numa rede ego não orientada, onde os nodos representam indivíduos e as arestas indicam contatos presenciais entre eles, a segmentação da rede em cinco comunidades pelo Algoritmo de Louvain, ilustrada na figura 5, pode ser interpretada da seguinte maneira:

- Comunidade 1 (verde): Esta comunidade pode representar um grupo de trabalho próximo do Ego, como uma equipa de projeto ou departamento dentro de uma empresa. Os membros têm um número moderado de conexões internas, sugerindo interações regulares, mas também um número significativo de conexões externas, indicando interações frequentes com outros grupos na rede;

- Comunidade 2 (amarela): Esta pode ser uma comunidade mais ampla, talvez representando uma turma universitária ou um grande grupo de amigos, onde o Ego tem uma participação central. A densidade interna mais baixa e o alto número de ligações externas sugerem que, enquanto há interações dentro da comunidade, muitos membros também se relacionam com pessoas de outras comunidades, o que pode refletir em encontros ocasionais ou atividades mistas;
- Comunidade 3 (laranja): Este grupo pode representar um pequeno grupo de colegas de trabalho que colaboram em projetos específicos ou um círculo restrito de amigos muito próximos. A alta densidade interna sugere um grupo muito coeso, onde quase todas as interações ocorrem dentro da comunidade, com poucas interações externas. Esse tipo de comunidade pode surgir em ambientes com alta frequência de interação e confiança mútua;
- Comunidade 4 (azul): Este grupo pode ser interpretado como uma rede de contatos mais fechada, possivelmente formada por um círculo familiar ou de vizinhança, onde as interações presenciais são comuns devido à proximidade geográfica ou laços familiares. A densidade interna relativamente alta indica laços fortes entre os membros, com quase todos os nodos conectados entre si, sugerindo um grupo coeso e com interações constantes;
- Comunidade 5 (rosa): Esta comunidade pode ser um grupo periférico em relação ao Ego, como um grupo de conhecidos ou membros de um clube que o Ego frequenta ocasionalmente. A baixa densidade interna e o número relativamente alto de ligações externas sugerem que, embora os membros interajam, as suas conexões internas não são tão fortes, e muitos também se relacionam com outros grupos, indicando interações mais esporádicas e menos intensas.

O nodo central (Ego) conecta-se a várias comunidades com diferentes características de coesão e interação. As comunidades podem refletir diferentes esferas da vida do Ego, como trabalho, estudos, vida social, e *hobbies*. A análise das métricas ajuda a entender o papel que cada comunidade desempenha no cotidiano do Ego, desde interações frequentes e próximas até laços mais ocasionais e menos intensos.

Conclusão

Cada método proporcionou uma perspectiva distinta sobre as estruturas da rede, mostrando variações nos tamanhos das comunidades e nos índices de modularidade. Essas diferenças podem indicar diversas formas de identificar agrupamentos de nodos, oferecendo percepções importantes sobre a organização

interna da rede. A variação nas dimensões das comunidades destaca a existência de agrupamentos heterogêneos, onde alguns grupos de nodos possuem conexões mais intensas entre si do que com o restante da rede.

No estudo de redes, estas descobertas sublinham a importância de utilizar diversos métodos para a identificação de comunidades, refletindo a complexidade e a riqueza das interações entre os elementos do sistema. Essa abordagem interdisciplinar proporciona uma visão mais abrangente das estruturas sociais e dos padrões de conexão, sendo essencial para a análise de sistemas complexos.


Os resultados alcançados não só ampliaram nossa compreensão sobre as características estruturais das redes e a detecção de comunidades, mas também ressaltaram a importância e a variedade de ferramentas analíticas disponíveis para explorar estes sistemas dinâmicos e interconectados.

Apêndice – código utilizado

```
#Importação das bibliotecas utilizadas
library(igraph)
library(dplyr)

# Leitura da rede

rede <- read_graph("Ligações T2.txt", format = ("edgelist"), directed
=F)
plot(rede, vertex.color="red", vertex.label.color="white")
```



```
ecount(rede)
```

```
## [1] 155
```

```
vcount(rede)
```


```
## [1] 51
```

Q1

```
# Método de remoção de pontes
```

```
crp <- cluster_edge_betweenness(rede)
```

```
plot(crp, rede)
```



```
# Avaliação do método
```

```
# i) - N° comunidades obtidas
```

```
length(crp)
```

```
## [1] 11
```

```
# Comunidade a que pertence cada nodo
```

```
membership(crp)
```

```
## [1] 1 2 1 1 1 2 3 3 2 2 1 4 1 5 6 2 1 7 1 8 3  
2 3 9 1
```

```
## [26] 1 3 2 1 2 2 3 10 11 1 1 1 3 1 1 4 1 2 7 8 2  
10 11 4 2
```

```
## [51] 2
```

```
# ii) - Dimensão de cada comunidade
```

```
num_nodos <- sapply(1:length(crp), function(c) {  
  length(which(membership(crp) == c))  
})
```

```

# iii) - Ligações internas de cada comunidade
ligacoes_internas <- sapply(1:length(crp), function(c) {
  comu <- induced_subgraph(rede, which(membership(crp) == c))
  ecount(comu)
})

# iii) - Densidade interna de cada comunidade
densidade_interna <- sapply(1:length(crp), function(c) {
  comu <- induced_subgraph(rede, which(membership(crp) == c))
  edge_count <- ecount(comu)
  node_count <- vcount(comu)
  round((edge_count * 2) / (node_count * (node_count - 1)), 2) # Densidade interna
})

# iv) - Ligações externas de cada comunidade
ligacoes_externas <- sapply(1:length(crp), function(c) {
  nodos_dentro <- which(membership(crp) == c)
  nodos_fora <- setdiff(V(rede), nodos_dentro)
  sum(sapply(nodos_dentro, function(n) {
    length(intersect(neighbors(rede, n), nodos_fora))
  })))
})

# Resultados
resultados <- data.frame(
  Comunidade = 1:length(crp),
  Numero_Nodos = num_nodos,
  Ligacoes_Internas = ligacoes_internas,
  Ligacoes_Externas = ligacoes_externas,
  Densidade_Interna = densidade_interna
)

# Exibir os resultados
print(resultados)

```

##	Comunidade	Numero_Nodos	Ligacoes_Internas	Ligacoes_Externas
## 1	1	17	47	50
## 2	2	13	32	24

```
## 3      3      7      14      13
## 4      4      3       2       7
## 5      5      1       0       1
## 6      6      1       0       2
## 7      7      2       1       2
## 8      8      2       1       3
## 9      9      1       0       1
## 10     10     2       1       4
## 11     11     2       1       5
```

```
##      Densidade_Interna
```

```
## 1      0.35
## 2      0.41
## 3      0.67
## 4      0.67
## 5      NaN
## 6      NaN
## 7      1.00
## 8      1.00
## 9      NaN
## 10     1.00
## 11     1.00
```

```
# vi) - Modularidade
```


```
modularity(crp)
```

```
## [1] 0.3222268
```

```
#Método Fast Greedy (otimização de modularidade)
```

```
cfg <- cluster_fast_greedy(rede)
```

```
plot(cfg, rede)
```



```

# Avaliação do método
# i) - N° comunidades obtidas
length(cfg)

## [1] 4

# Comunidade a que pertence cada nodo
membership(cfg)

## [1] 2 1 3 2 2 1 3 3 1 1 2 1 2 4 1 1 3 4 2 4 3 1 3 4 2 4 3 1 2 1 1
3 4 2 4 2 2 3

## [39] 4 3 1 3 1 4 4 1 4 2 1 1 1

# ii) - Dimensão de cada comunidade
num_nodos <- sapply(1:length(cfg), function(c) {
  length(which(membership(cfg) == c))
})

# iii) - Ligações internas de cada comunidade
ligacoes_internas <- sapply(1:length(cfg), function(c) {
  comu <- induced_subgraph(rede, which(membership(cfg) == c))
  ecount(comu)
})

# iii) - Densidade interna de cada comunidade
densidade_interna <- sapply(1:length(cfg), function(c) {
  comu <- induced_subgraph(rede, which(membership(cfg) == c))
  edge_count <- ecount(comu)
  node_count <- vcount(comu)
  round((edge_count * 2) / (node_count * (node_count - 1)), 2) # Densidade interna
})

# iv) - Ligações externas de cada comunidade
ligacoes_externas <- sapply(1:length(cfg), function(c) {
  nodos_dentro <- which(membership(cfg) == c)
  nodos_fora <- setdiff(V(rede), nodos_dentro)
  sum(sapply(nodos_dentro, function(n) {
    length(intersect(neighbors(rede, n), nodos_fora))
  }))
})

```

```

# Resultados
resultados <- data.frame(
  Comunidade = 1:length(cfg),
  Numero_Nodos = num_nodos,
  Ligacoes_Internas = ligacoes_internas,
  Ligacoes_Externas = ligacoes_externas,
  Densidade_Interna = densidade_interna
)

# Exibir os resultados
print(resultados)

##   Comunidade Numero_Nodos Ligacoes_Internas Ligacoes_Externas Densidade_Interna
## 1           1           17              38              25
## 0.28
## 2           2           12              20              25
## 0.30
## 3           3           11              23              27
## 0.42
## 4           4           11              13              45
## 0.24


# vi) - Modularidade
modularity(cfg)

## [1] 0.3484287

# Algoritmo de Louvain (otimização de modularidade)

set.seed(111)
cl <- cluster_louvain(rede)
plot(cl, rede)

```



```

# Avaliação do método
# i) - N° comunidades obtidas
length(cl)
## [1] 5

# Comunidade a que pertence cada nodo
membership(cl)
## [1] 1 2 1 1 1 3 4 4 3 3 1 2 5 2 2 2 2 2 1 2 4 3 4 2 1 2 4 2 5 3 3
4 2 5 5 1 1 4
## [39] 5 5 2 5 3 2 2 3 2 5 2 2 3

# ii) - Dimensão de cada comunidade
num_nodos <- sapply(1:length(cl), function(c) {
  length(which(membership(cl) == c))
})

# iii) - Ligações internas de cada comunidade
ligacoes_internas <- sapply(1:length(cl), function(c) {
  comu <- induced_subgraph(rede, which(membership(cl) == c))
  ecount(comu)
})

# iii) - Densidade interna de cada comunidade
densidade_interna <- sapply(1:length(cl), function(c) {
  comu <- induced_subgraph(rede, which(membership(cl) == c))
  edge_count <- ecount(comu)
  node_count <- vcount(comu)
  round((edge_count * 2) / (node_count * (node_count - 1)), 2) # Densidade interna
})

# iv) - Ligações externas de cada comunidade
ligacoes_externas <- sapply(1:length(cl), function(c) {
  nodos_dentro <- which(membership(cl) == c)
  nodos_fora <- setdiff(V(rede), nodos_dentro)
  sum(sapply(nodos_dentro, function(n) {
    length(intersect(neighbors(rede, n), nodos_fora))
  })))
})

```

```

}))

# Resultados
resultados <- data.frame(
  Comunidade = 1:length(cl),
  Numero_Nodos = num_nodos,
  Ligacoes_Internas = ligacoes_internas,
  Ligacoes_Externas = ligacoes_externas,
  Densidade_Interna = densidade_interna
)

# Exibir os resultados
print(resultados)

```

	Comunidade	Numero_Nodos	Ligacoes_Internas	Ligacoes_Externas	Densidade_Interna
## 1 0.47	1	9	17	21	
## 2 0.21	2	18	32	46	
## 3 0.56	3	9	20	21	
## 4 0.67	4	7	14	13	
## 5 0.36	5	8	10	23	


```

# vi) - Modularidade
modularity(cl)
## [1] 0.3671592

# Método propagação de etiquetas

set.seed(111)
cpe <- cluster_label_prop(rede)
plot(cpe, rede)

```



```
# Avaliação do método
# i) - N° comunidades obtidas
length(cpe)
## [1] 2

# Comunidade a que pertence cada nodo
membership(cpe)
## [1] 1 1 1 1 1 1 2 2 1 1 1 1 1 1 1 1 1 1 2 1 2 1 1 1 2 1 1 1 1
2 1 1 1 1 1 2
## [39] 1 1 1 1 1 1 1 1 1 1 1 1 1 1

# ii) - Dimensão de cada comunidade
num_nodos <- sapply(1:length(cpe), function(c) {
  length(which(membership(cpe) == c))
})

# iii) - Ligações internas de cada comunidade
ligacoes_internas <- sapply(1:length(cpe), function(c) {
  comu <- induced_subgraph(rede, which(membership(cpe) == c))
  ecount(comu)
})

# iii) - Densidade interna de cada comunidade
densidade_interna <- sapply(1:length(cpe), function(c) {
  comu <- induced_subgraph(rede, which(membership(cpe) == c))
  edge_count <- ecount(comu)
  node_count <- vcount(comu)
  round((edge_count * 2) / (node_count * (node_count - 1)), 2) # Densidade interna
})
```

```

# iv) - Ligações externas de cada comunidade
ligacoes_externas <- sapply(1:length(cpe), function(c) {
  nodos_dentro <- which(membership(cpe) == c)
  nodos_fora <- setdiff(V(rede), nodos_dentro)
  sum(sapply(nodos_dentro, function(n) {
    length(intersect(neighbors(rede, n), nodos_fora))
  }))
})

# Resultados
resultados <- data.frame(
  Comunidade = 1:length(cpe),
  Numero_Nodos = num_nodos,
  Ligacoes_Internas = ligacoes_internas,
  Ligacoes_Externas = ligacoes_externas,
  Densidade_Interna = densidade_interna
)

# Exibir os resultados
print(resultados)

```

	Comunidade	Numero_Nodos	Ligacoes_Internas	Ligacoes_Externas	Densidade_Interna
## 1	1	44	128	13	0.14
## 2	2	7	14	13	0.67

```

# vi) - Modularidade
modularity(cpe)
## [1] 0.1456608

```