

ISCTE - Licenciatura em Ciência de Dados

Cross Validation

UC Modelação Estocástica

Docente: Catarina Marques

Discentes: Camila Sousa e Carolina Brunheta, CDC1

Outubro de 2024

A validação cruzada (CV) é uma técnica de reamostragem fundamental na avaliação do desempenho de modelos preditivos em conjuntos de dados. O objetivo principal é estimar a capacidade de generalização de um modelo para novos dados, ajudando na seleção de modelos e otimização de parâmetros.

Os métodos mais comuns de validação cruzada incluem: **Clássico** - Divide os dados em dois grupos fixos, um para treino e outro para teste; simples, mas pode variar o resultado dependendo da divisão; ***k-fold Cross Validation*** - divide os dados em k subconjuntos (ou *folds*). O modelo é treinado k vezes, cada vez utilizando $k-1$ *folds* para treino e 1 *fold* para validação; ***Leave-One-Out Cross Validation (LOOCV)*** ou ***n-fold CV*** - cada observação é utilizada uma vez como conjunto de validação, enquanto as demais são usadas para treino. Isto é repetido n vezes (n° de observações). Este método tende a ter menor enviesamento, mas é mais intensivo computacionalmente, especialmente em grandes conjuntos de dados.

Pretende-se estimar um modelo de regressão que descreva adequadamente o processo de geração de Y com base em X . Para esse efeito, propõem-se dois modelos, com o objetivo de escolher aquele que, de entre os dois, produz um erro de previsão menor: **Regressão Linear Simples** - técnica que procura modelar a relação entre uma variável independente x e uma variável dependente y através da equação da reta: $y = \beta_0 + \beta_1 x + \varepsilon$ onde β_0 é o *intercept*, β_1 é o coeficiente angular e ε representa o erro aleatório. Este modelo assume que a relação entre x e y é linear, o que pode ser uma limitação em dados com comportamentos não lineares; **Regressão Polinomial de Terceiro Grau** - modela a relação entre as variáveis através de uma equação polinomial. A equação para este modelo é dada por: $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \varepsilon$. Este modelo permite capturar relações não lineares de forma mais eficaz, pois considera termos quadráticos e cúbicos de x .

Os modelos foram avaliados utilizando LOOCV e *k-fold CV*. O erro quadrático médio (MSE) foi utilizado como métrica de desempenho. O MSE quantifica a média dos erros ao quadrado entre os valores observados e as previsões do modelo, sendo definido como: $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$. Os resultados dos modelos foram avaliados para diferentes números de *folds*, variando de 2 a 100 em *k-folds CV* e n *folds* para LOOCV. Esta abordagem permite explorar o *trade-off* entre o enviesamento e variância, uma vez que a escolha do número de *folds* pode impactar a estimativa do erro do modelo.





Tabela de Erro Quadrático Médio (MSE) para Modelos Linear e Polinomial		
Número de Folds	Modelo Linear (MSE)	Modelo Polinomial (MSE)
LOOCV	540.1336	1.031135
2	550.4690	1.028514
5	539.6507	1.036220
7	540.5162	1.029766
10	540.6747	1.030827
20	539.8635	1.031672
50	540.4000	1.030511
100	540.4143	1.030941

Os resultados obtidos na validação cruzada demonstraram que o modelo de regressão polinomial de terceiro grau apresentou consistentemente um MSE significativamente inferior em comparação ao modelo linear simples. Isto sugere que o modelo polinomial é mais eficaz a capturar a complexidade dos dados. A análise da distribuição dos dados revelou uma natureza não linear, reforçando a escolha do modelo polinomial como mais apropriado.

Além disso, a consistência dos resultados indica que a escolha do número de *folds* não teve um impacto significativo no desempenho do modelo. Comprovou-se que, neste caso, a utilização de menos *folds* pode ser vantajosa, pois reduz o esforço computacional sem comprometer a qualidade da estimativa do erro. Assim, quando a diferença no erro entre diferentes números de *folds* é quase nula, é mais eficiente optar por um menor número de *folds*.

Conclui-se que a regressão polinomial de terceiro grau (ex: $Y = -23.09129 + 890.90387x + (-691.82899)x^2 + 240.41067x^3$) é a escolha ideal para modelar a relação entre as variáveis em questão.